

الفهرس

3	ملخص تجريدي
3	مقدمة
3	الكلمات المفتاحية
3	الدراسة المرجعية
4	اولا. الأعمال المشابهة
4	ثانيا. نموذج تحليل المشاعر في النصوص
5	A. معالجة النص Text Preprocessing
5	B. استخراج الميزات features extraction ،
5	C. التصنيف classification
8	طريقة التقييم وقياسات الأداء
10	بيانات التدريب :
11	تصنيف بيانات التدريب:
12	نتائج والتقييم:
13	النتائج التي تم الحصول عليه عند عينة التدريب :
14	النتائج التي تم الحصول عليه عند عينة الاختبار :
15	النتائج التي تم الحصول عليه عند اخذ عينة عشوائية :
15	طرق اخرى :
16	المصادر

ملخص تجريدي

إن الحاجة إلى فهم وتحليل المشاعر في النصوص العربية تزداد أهمية في عصر البيانات الكبيرة والتواصل الرقمي. يعرض هذا المشروع نظامًا متقدمًا لتحليل المشاعر في النصوص العربية، مستخدمًا تقنيات التعلم الآلي والشبكات العصبية. يغطي المشروع عدة جوانب رئيسية تشمل:

1. بيانات التدريب التركيز على جمع وتصنيف بيانات التدريب اللازمة لتطوير نموذج قادر على تحديد المشاعر المختلفة في النصوص العربية بدقة.
 2. المعالجة الأولية للنصوص: استخدام تقنيات معالجة النصوص لتحضير البيانات قبل تغذيتها إلى النموذج، بما في ذلك تنظيف البيانات وتوحيدها.
 3. تحويل النصوص إلى أشعة رقمية: تحويل النصوص العربية إلى صيغة رقمية مناسبة لمعالجتها بواسطة خوارزميات التعلم الآلي.
 4. إعداد الشبكة العصبية: تصميم وتطوير نموذج الشبكة العصبية الذي يشمل طبقات التضمين، LSTM، والطبقات الكثيفة لتحليل المشاعر بكفاءة.
 5. معايرة المعاملات الفائقة: تنفيذ تقنيات مثل البحث الشبكي مع التقييم المتقاطع لتحسين أداء النموذج والوصول إلى نتائج دقيقة.
 6. **التطبيقات والأهمية: يسلط المشروع الضوء على أهمية تحليل المشاعر في النصوص العربية وتطبيقاته المتنوعة في مجالات مثل خدمة العملاء، التحليلات الاجتماعية، والذكاء الاصطناعي التفاعلي.
- يهدف هذا المشروع إلى تقديم نظرة شاملة على كيفية تطوير وتنفيذ نظام تحليل المشاعر باللغة العربية، مع التركيز على الدقة، الكفاءة، والقدرة على التكيف مع النصوص المتنوعة.

مقدمة

في عالم اليوم، حيث تتزايد البيانات النصية بشكل مستمر على الإنترنت، تبرز الحاجة الملحة لتطوير أنظمة قادرة على فهم وتحليل هذه البيانات. يكتسب تحليل المشاعر أهمية خاصة نظرًا لقدرته على استخراج الآراء والعواطف من النصوص، والتي تعد مفتاحًا لفهم السياقات الاجتماعية والثقافية. يتناول مشروعنا "تحليل المشاعر في النصوص العربية" هذا التحدي، مع التركيز بشكل خاص على اللغة العربية.

تعتبر اللغة العربية واحدة من أكثر اللغات تحديًا في مجال معالجة اللغات الطبيعية بسبب تعقيدها النحوي والصرفي. يهدف هذا المشروع إلى تطوير نظام تحليل المشاعر الذي يتعامل بكفاءة مع خصائص النصوص العربية، ويوفر تحليلًا دقيقًا للمشاعر المعبر عنها فيها. من خلال استخدام تقنيات التعلم الآلي والشبكات العصبية، نسعى لتطوير نموذج يتميز بقدرته على التعلم من البيانات والتكيف مع الأنماط المختلفة للغة العربية.

تتضمن الخطوات الأساسية في هذا المشروع جمع بيانات التدريب، المعالجة الأولية للنصوص، تحويل النصوص إلى أشعة رقمية، تصميم وتطوير الشبكة العصبية، ومعايرة المعاملات الفائقة لتحسين أداء النموذج. يسعى المشروع لتقديم نهج شامل يضمن التعامل مع تحديات تحليل المشاعر في النصوص العربية، ويفتح آفاقًا جديدة لتطبيقات عملية في مجالات متعددة مثل تحليل البيانات الاجتماعية، خدمات العملاء، وتطوير الذكاء الاصطناعي.

الكلمات المفتاحية

- Arabic Sentiment Analysis;
- Twitter
- Semantic Relations
- Arabic Word Net
- Machine Learning

الدراسة المرجعية

تعتبر الدراسة المرجعية جزءاً أساسياً في مشروعنا حول تحليل المشاعر في النصوص العربية، حيث تقدم إطاراً نظرياً وتاريخياً لفهم الجهود السابقة والتطورات في هذا المجال.

يُعد تحليل المشاعر، المعروف أيضًا باسم استخراج الآراء، دراسة حسابية لآراء ومشاعر واتجاهات الأشخاص حول مواضيع وكيانات وأحداث معينة يتم التعبير عنها في النصوص.

الهدف من تحليل المشاعر هو تعيين فئة مشاعر محددة مسبقًا للنصوص الإلكترونية، مثل تصنيفها على أنها سلبية، إيجابية، أو محايدة.

يلعب تحليل المشاعر دورًا هامًا في العديد من المجالات مثل التمويل، التسويق،

نظرة سريعة على الأعمال المشابهة في هذا المجال

اولا. الأعمال المشابهة

- sentiment classification for Arabic tweets

نموذج لتصنيف المشاعر للتغريدات باللغة العربية.

استخدموا مجموعات مختلفة من ميزات N-gram (أي تجزئة النصوص إلى مجموعات من n كلمات متتالية) مع مصنفات (NB) و (SVM).

- SA model for Arabic Twitter and Facebook comments

بنوا نموذجًا لتحليل المشاعر لتغريدات تويتر وتعليقات فيسبوك باللغة العربية، واستخدموا ميزات B-gram مع مخططات , كما قاموا بالتحقيق في تأثير استخدام مصطلح التردد (TF) ومصطلح التردد المعكوس (IF) مخططات وزن تردد الوثيقة (TF-IDF) مع SVM، مصنفات NB و K- (K-NN)

- presented a subjectivity and sentiment analysis system (SAMAR)

المعتمد على مصنف SVM لتطبيقات التواصل الاجتماعي العربية المختلفة: منتديات الويب، الدردشة، صفحات نقاش ويكيبيديا، وتويتر. لقد درسوا بشكل مختلف الميزات بما في ذلك Word n-grams ووضع علامات على

- word n-grams,
- POS tagging,
- word stems

بالإضافة إلى العديد من الميزات الأسلوبية المتعلقة بوسائل التواصل الاجتماعي تم التحقيق في التطبيقات. وأظهرت النتائج أن يعتمد أداء المصنف على نوع مجموعة البيانات و الميزات المستخدمة.

- تم مناقشة الأعمال المشابهة ويوجد ايضا غيرهم لكن اكتفينا بالثلاثة

ثانيا. نموذج تحليل المشاعر في النصوص

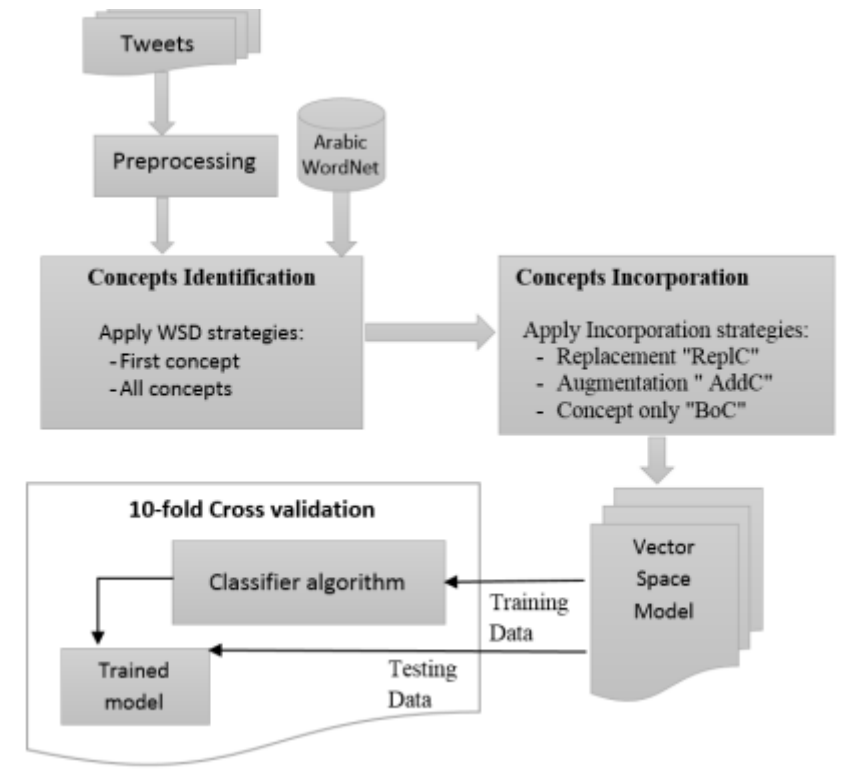
نموذج SA لبيانات بناءً على التعلم الآلي تم تطوير النهج. الهيكل العام ويتكون النموذج من مرحلتين رئيسيتين، **التدريب والاختبار**. في

- **مرحلة التدريب**، يحتاج المصنف إلى التعلم من مجموعة من تغريدات مصنفة. ثم تم استخدامه لتصنيف التغريدات غير المسماة مرحلة الاختبار.

وتتكون كل مرحلة من الخطوات التالية:

- A. معالجة النص Text Preprocessing**
- B. استخراج الميزات features extraction**
- C. التصنيف classification**

تم توضيح العملية العامة لنموذج في الشكل 1.



أولاً، يجب جمع مجموعات بيانات التغريدات والتعليق عليها. بعد ذلك، تمت معالجة التغريدات مسبقاً لإزالة الضوضاء. ومن ثم تم بناء نموذج تمثيل الميزات. هذا الخطوة أمر بالغ الأهمية لأن نوع الميزات المستخرجة والطريقة التي يتم بناؤها بها تؤثر على أداء المصنف ML. كان هناك نوعان مختلفان من الميزات المستخرجة، BoW and semantic concepts features التي كانت تستخدم في بناء نماذج تمثيل النصوص. وأخيراً، ML

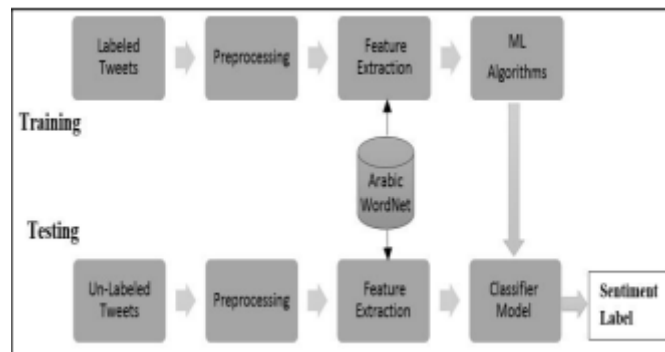
يتم تدريب المصنف وتقييمه على البيانات غير المسماة.

A. Text Preprocessing

تعد المعالجة المسبقة للنص خطوة أساسية في بيانات المدونات الصغيرة لتنظيف التغريدات المدخلة والتخلص من الضوضاء والبيانات غير الضرورية تتكون المعالجة المسبقة من الخطوات التالية:

1. إضافة العلامات Adding Tags

في تويتر، يعبر الأشخاص عن مشاعرهم باستخدام طرق مختلفة الرموز التعبيرية. هكذا ظهرت الرموز التعبيرية في التغريدات تتطلب معالجة خاصة. علاوة على ذلك، بعض علامات الترقيم العلامات، مثل علامة التعجب ("!") وعلامة الاستفهام ("؟")، مرتبطة بعواطف الناس، في هذه الخطوة، يتم استبدال الرموز التعبيرية بما يقابلها علامات الكلمات ذات المعنى التي تمثل مشاعرهم.



أمثلة يتم عرض الرموز التعبيرية المستخدمة في الجدول.

2. تنظيف البيانات Data Cleaning

يعد تنظيف البيانات مهمة حاسمة للتعامل مع الضوضاء طبيعة بيانات تويتر. تتكون هذه الخطوة من إزالة العناصر من التغريدات التي لا تتضمن أي مشاعر. على هذا النحو، تمت إزالة العناصر التالية:

- a. حذف اشارات الترقيم المختلفة كالفواصل و اشارات الاستفهام وغيرها،
b. وكيانات إعادة التوحيد (RT)،
c. أسماء المستخدمين،
d. حذف الأرقام الواردة في النص
e. الحروف العربية المفردة،
f. الحروف غير الحروف
g. تجزيع الكلمات Steaming

3. التطبيع Normalization

من أجل الإنتاج أشكال الكلمات متسقة. التطبيع للنص العربي

يتكون من الخطوات التالية:

مهمة التطبيع مهمة لإنتاج أشكال كلمات متسقة. يتألف التطبيع للنص العربي من الخطوات التالية:

- إزالة الحركات: مثل تحويل "العَرْبِيَّة" إلى "العربية".
- إزالة التطويل (التشكيل): مثل تحويل "العربيّة" إلى "العربية".
- إزالة "ال" من بداية الكلمات: مثل تحويل "العربية" إلى "عربية".
- استبدال الحرف "هـ" بـ"ه".
- استبدال الحرف "ي" بـ"ى".
- استبدال الحروف "آ-أ-إ" بـ"ا".
- توحيد الحروف المكررة: مثل تحويل "سعاااادة" إلى "سعادة".

4. الترميز Tokenization

في هذه الخطوة، تم تقسيم نص التغريدة إلى سلسلة من الرموز حيث يمثل كل رمز كلمة واحدة بناءً على White Space.

5. إزالة كلمات التوقف Stop Words Removal

هي الكلمات التي تتكرر كثيراً في النصوص كأحرف الجر (من، الى، ...) والضمائر (أنا، هو)، ... وغيرها،

Symbols	The Tags
“:”)”, “:-)”, “:)”	HAPPY
“:(”, “:-(", “: (“	SAD
!	Exclamation
?	Question

B. Features Extraction

تتطلب خوارزميات التعلم الآلي الإشرافي تمثيل المستندات بشكل مناسب كمتجه للميزات. تستخدم غالبية خوارزميات التعلم الآلي نموذج فضاء المتجهات (VSM)، حيث يتم تمثيل كل مستند كمتجه ميزات موزون. تم إنشاء نماذج تمثيل نصية مختلفة للتغريدات بناءً على ميزتين مستخرجتين: كيس الكلمات (BoW) والمفاهيم الدلالية (semantic concepts). تحتاج الميزات إلى التوزيع باستخدام مخطط تواتر الكلمة-تواتر المستند العكسي (TF-IDF). يساعد هذا المخطط في تقليل وزن الميزات التي تظهر في مستندات متعددة في المجموعة البيانات. يُعرف كما يلي:

$$TF\text{-}IDF(f_n, d_i) = TF(f_n, d_i) \cdot IDF(f_n) \quad (1)$$

where $TF(f_n, d_i)$ is the frequency of the feature f_n , $IDF(f_n)$ is defined as:

$$IDF(f_n) = \log \frac{|D|}{DF(f_n)} \quad (2)$$

where $DF(f_n)$ refers to the number of documents in D that include the feature f_n . The $|D|$ is the total number of documents in the dataset.

1) The Bag-of-Words Representation

أظهر النموذج BoW المستخدم في معظم تطبيقات تعدين النصوص فعاليته في مجال تحليل العواطف. لبناء متجهات الميزات، يُعتبر النموذج الكلمات كجوانب معلوماتية أساسية للنصوص. يتكون من كلمات مميزة تظهر في المجموعة البيانات بعد معالجة التغريدات. بدلاً من الاعتماد فقط على ميزات الكلمات، يتم استخدام رموز الرموز التعبيرية كميزات إضافية مع نموذج BoW للدلالة على العاطفة في النصوص العربية.

2) Concepts Representation تمثيل المفاهيم

يتجاهل تمثيل التغريدات بنماذج BoW العلاقات الدلالية بين الكلمات. نتيجة لذلك، يتم تمثيل الكلمات المترادفة التي تظهر في تغريدتين كميزات مستقلة مختلفة، ولن يكتشف النموذج أي ميزات ذات صلة بين التغريدات. اقترح هذا العمل تمثيل التغريدات في فضاءها الدلالي من خلال دمج المفاهيم الدلالية في فضاء ميزات التغريدات. يساعد هذا في تصنيف العاطفة للتغريدات التي لم تذكر أي كلمات موجودة في مجموعة بيانات التدريب، لكنها تحتوي على كلمات مترادفة مماثلة.

C. Classification

1. تصنيف التغريدات إلى ثلاث فئات:

يتم تصنيف التغريدات بشكل سريع وآلي إلى ثلاث فئات مختلفة:

- **التغريدات الموجبة:** تشمل التغريدات التي تحمل معاني إيجابية تعبر عن الرضا والارتياح.
- **التغريدات السالبة:** تضم التغريدات التي تحمل معاني سلبية وتعبر عن الاستياء.
- **التغريدات المحايدة:** تشمل التغريدات التي لا تحمل معاني موجبة أو سالبة ولا تعطي معلومات محددة عن المشاعر.

2. بناء مصنف حاسوبي آلي:

- يتم تعلم بناء مصنف حاسوبي آلي يقوم بتصنيف أي جملة عربية إلى محايدة أو سالبة أو موجبة.
- يُظهر هذا النهج كيفية استخدام التحليل الآلي لتحديد المشاعر المعبر عنها في التغريدات بطريقة فعالة وسريعة.

طريقة التقييم وقياسات الأداء

المقاييس الأساسية المستخدمة في تقييم هي

- precision
- recall
- accuracy
- mean average precision (MAP)
-

- الدقة (Precision): هي عدد المصنف بشكل صحيح التغريدات الإيجابية مقسومة على عدد التغريدات التي تم تصنيفها على أنها إيجابية من قبل النظام. يتم تعريفه على النحو التالي:

$$P = \frac{\text{True Positive}}{\text{True Positive} + \text{False Positive}} \quad (3)$$

- الاستدعاء (Recall)، هو عدد المصنف بشكل صحيح التغريدات الإيجابية مقسومة على عدد التغريدات الإيجابية في

dataset. يتم تعريفه على النحو التالي:

$$R = \frac{\text{True Positive}}{\text{True Positive} + \text{False Negative}} \quad (4)$$

- بالنظر إلى P و R، يتم تعريف قياس F على أنه

$$F = 2 \cdot \frac{P \cdot R}{P + R} \quad (5)$$

بالاعتماد على ورقة بحثية وداتا سبت التي جمعها في الورقة بحثية تم تجربة مودل على نوعين من **Features**

- Svm
- NB

- هذه نتائج تم جمعها من خلال تطبيق المودل الذي تم اعتماد عليه من ورقة بحثية ومشابه جدا لمشروعنا ، لضيق الوقت تم اعتماد على هذه نتائج كونها قريبة من نتائج التي تم استخراجها من مشروعنا .

- تم إنشاء مجموعة تويتر باللغة العربية لـ SA من خلال التجميع تغريدات تتعلق بمشاعر الناس في مجالات مختلفة (السياسة والرياضة والاجتماعية والشركات). لآتمته العملية،

- تتألف مجموعة البيانات النهائية من حوالي 826 نص تغريدة وثيقة تتكون من **413 تغريدة إيجابية** و**413 تغريدة سلبية**

features	NB		SVM	
BoW	85.99		91.15	
	<i>AllC</i>	<i>FstC</i>	<i>AllC</i>	<i>FstC</i>
Concepts only	85.96	89.14	87.04	93.7
Concepts (AddC)	89.72	91.77	92.59	95.63
Concepts (ReplC)	86.79	88.93	90.87	95.11

في هذه الخطوة يتم استخراج المفاهيم الدلالية من التغريدات تم دمجها كميزات إضافية لتمثيل التغريدات. كان اقترح استخدام استراتيجيات التأسيس المختلفة (تعزيز "AddC"، واستبدال "ReplC"، والمفهوم فقط "BoC")

1-Augmentation "AddC"

تعمل هذه الإستراتيجية على تعزيز المفاهيم المحددة في التغريدات في نموذج BoW كميزات إضافية مع الكلمات المقابلة. باستخدام استراتيجية "AddC"، فإن التغريدات يتم تمثيلها بجميع المفاهيم المستخرجة وجميع التغريدات كلمات. في هذه الاستراتيجية، يتم تكبير حجم الميزات بمقدار المفاهيم الدلالية، ويتم تعريف الحجم الجديد

كـ

$$|c| + |F| = |F'|$$

حيث |F| هو إجمالي عدد الميزات،

|F| هو الابتدائي حجم الميزة،

|C| هو عدد المفاهيم الدلالية المرتبطة بالكلمات

2) Replacement "ReplC"

تستبدل هذه الإستراتيجية كل الكلمات بمفاهيمها المعينة تم تحديدها في التغريدات. باستخدام استراتيجية "ReplC"، التغريدات ممثلة بمفاهيم وكلمات ليس لها خريطة المفاهيم في AWN. تساعد هذه الإستراتيجية في تقليل الميزات مساحة، حيث يتم تعريف الحجم الجديد

كـ

$$|C| + |WC| - |F| = |F'|$$

حيث $|WC|$ هو العدد الإجمالي للكلمات الفردية التي تم استبدالها بالمفاهيم

3) Concept Only "BoC "

في هذه الاستراتيجية، يتم تمثيل التغريدات من خلال المستخرجة منها مفهوم فقط دون أي من كلماتهم. باستخدام بنك كندا

الإستراتيجية، حجم مساحة الميزة هو نفس حجم مساحة الميزة

المفاهيم الدلالية المستخرجة

$$|F'| = |C|$$

بيانات التدريب :

- تحوي مجموعة البيانات المتاحة حوالي 23500 تغريدات لتعليقات الأشخاص وملاحظاتهم حول مجموعة من الأماكن العامة في المملكة العربية السعودية. جُمعت هذه التغريدات عن طريق مجموعة من الطلاب الجامعيين وذلك من مجموعة متنوعة من مواقع التواصل الاجتماعي.

نُعطى فيما يلي أمثلة عن هذه التغريدات، تعليقات حول حديقة حيوانات مثلاً:

- "أنصحكم والله بزيارتها، مكان جميل جداً مرتب ونظيف"
- "جميلة وكبيرة وتحتاج واحد عنده لياقة يمشي فيها"
- "حيوانات قليلة جداً ولا يوجد اهتمام مكثف"
- "كان يعيبها وقت الافتتاح والإغلاق وعدم وجود خريطة"
- "أول مرة أزور حديقة حيوانات"
- "أيام العوائل: الخميس والجمعة والسبت"

يُمكننا، كبشر، تصنيف التغريدات السابقة وبشكل سريع إلى ثلاث فئات:

- **التغريدات الموجبة (الأولى والثانية):** أي التغريدات التي تحمل معاني إيجابية تُعبر عن الرضا والارتياح.
- **التغريدات السالبة (الثالثة والرابعة):** أي التغريدات التي تحمل معاني سلبية تُعبر عن الاستياء.
- **التغريدات المحايدة (الخامسة والسادسة):** أي التغريدات التي يُمكن أن تُعطي معلومات ولا تحمل أية مشاعر فيها سواء موجبة أم سالبة.

نتعلم في هذا المشروع بناء مصنّف حاسوبي آلي يُصنّف أي جملة عربية إلى موجبة أو سالبة أو محايدة.

تصنيف بيانات التدريب:

يتطلب استخدام خوارزميات تعلم الآلة خوارزميات تصنيف النصوص في حالتنا توفر بيانات للتدريب أي مجموعة من النصوص مُصنّفة مسبقاً إلى:

- موجبة
- سالبة
- محايدة

يُمكن، في بعض الأحيان، اللجوء إلى الطرق اليدوية: أي الطلب من مجموعة من الأشخاص قراءة النصوص وتصنيفها. وهو حل يصلح في حال كان عدد النصوص صغيراً نسبياً. يتميز هذا الحل بالدقة العالية لأن الأشخاص تُدرِك، بشكل عام، معاني النصوص من خلال خبرتها اللغوية المكتسبة وتُصنّف النصوص بشكل صحيح غالباً.

نستخدم، في حالتنا، حلاً إحصائياً بسيطاً لتصنيف نصوص التدريب إلى موجبة، سالبة، محايدة وذلك باستخدام قاموس للكلمات الموجبة وقاموس آخر للكلمات السالبة.

يحتوي قاموس الكلمات الموجبة على مجموعة من الكلمات الموجبة الشائعة مع نقاط لكل كلمة (1 موجبة، 2 موجبة جداً، 3 موجبة كثيراً). مثال:

• روعة 3

• جيد 2

• معقول 1

يحتوي قاموس الكلمات السالبة على مجموعة من الكلمات السالبة الشائعة مع نقاط لكل كلمة (-1 سالبة، -2 سالبة جداً، -3 سالبة كثيراً). مثال:

• مقرف -3

• سيء -2

• زحمة -1

اختيرت كلمات القواميس الموجبة والسالبة من قبل مجموعة من الطلاب وانتقاء الكلمات التي تُعطي التغيرات معنى موجب أو معنى سالب، وإعطاء كل كلمة موجبة نقاط تدل على شدة الإيجابية لها (1،2،3) وكل كلمة سالبة نقاط تدل على شدة السلبية لها (-1،-2،-3).

نعدّ، فيما يلي، نصاً ما أنه موجب إذا كان مجموع نقاط الكلمات الموجبة الواردة ضمن النص أكبر من مجموع نقاط الكلمات السالبة الواردة ضمنه. وبالمقابل، نعدّ نصاً ما أنه سالب إذا كان مجموع نقاط الكلمات السالبة الواردة ضمن النص أكبر من مجموع نقاط الكلمات الموجبة الواردة ضمنه. نعدّ نصاً ما محايداً إذا تساوى مجموع نقاط الكلمات الموجبة فيه مع مجموع نقاط الكلمات السالبة.

بالطبع، لا تُعدّ هذه الطريقة صحيحة دوماً إذ يُمكن أن تُخطئ في بعض الحالات إلا أنها على وجه العموم تُستخدم عوضاً عن الطريقة اليدوية.

نتائج والتقييم:

- بعد تدريب المودل على 16428 عينة التدريب و 4107 عينة الاختبار

النتائج التي تم الحصول عليه عند عينة التدريب :

1- الطبقة الأولى: طبقة التضمين (Embedding)

- "نستخدم هذه الطبقة لتوليد ترميز كثيف للكلمات (dense word encoding)، مما يُساهم في تحسين عملية التعلم. نطلب تحويل الشعاع الذي طوله (length_input) والذي في حالتنا هو 50، والذي يحوي قيماً ضمن المجال (dim_input) من 1 إلى 5000 في مثالنا، إلى شعاع من القيم ضمن المجال (dim_output) مثل 32 قيمة."


2- الطبقة الثانية: LSTM

- "يُحدد المعامل (units) عدد الوحدات المخفية لهذه الطبقة. يُساهم المعامل (dropout) في معايرة الشبكة خلال التدريب، حيث يقوم بإيقاف تشغيل الوحدات المخفية بشكل عشوائي أثناء التدريب، وبذلك تجبر الشبكة نفسها على العثور على أنماط أكثر أهمية في البيانات من أجل زيادة المقياس الذي تحاول تحسينه، مثل الدقة، بدلاً من الاعتماد على نسبة 100% من جميع الخلايا العصبية الخاصة بها."

3- الطبقة الثالثة: Dense

يُحدّد المعامل units حجم الخرج لهذه الطبقة (3 في حالتنا: 0 سالبة، 1 محايدة، 2 موجبة)

يكون للمنحنى الشكل التالي:



النتائج التي تم الحصول عليه عند عينة الاختبار :

المقياس	(%) القيمة
الدقة (Accuracy)	90.11
الدقة (Precision)	90.90
الاستدعاء (Recall)	90.11
F1 (F1-Score) مقياس	90.32

1. دقة النموذج على بيانات الاختبار (Model Accuracy): تبلغ نسبة الدقة 90.11%، مما يعني أن النموذج تمكن من تصنيف حوالي 90.11% من التغريدات بشكل صحيح.

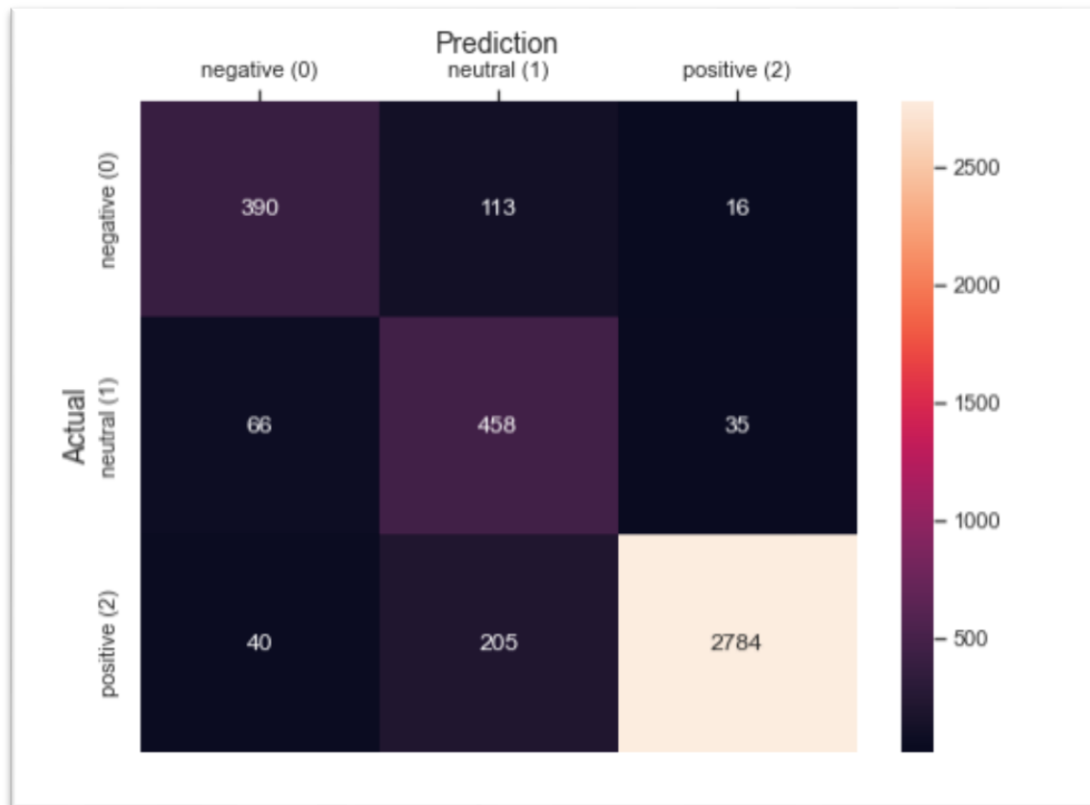
2. الدقة (Precision) على بيانات الاختبار: تبلغ نسبة الدقة في التصنيف 90.90%، وهذا يشير إلى أن النموذج كان دقيقاً في التصنيفات التي قام بها.

3. الاستدعاء (Recall) على بيانات الاختبار: تبلغ نسبة الاستدعاء 90.11%، وهذا يعكس قدرة النموذج على اكتشاف وتصنيف التغريدات بشكل صحيح.

4. مقياس F1 على بيانات الاختبار: يبلغ مقياس F1 حوالي 90.32%، وهذا يدل على توازن جيد بين الدقة والاستدعاء في النموذج.

5. مصفوفة الارتباك (Confusion Matrix):

- التغريدات السالبة: 390 صحيحة، 113 خطأ في السلبية، 16 خطأ في الإيجابية.
- التغريدات المحايدة: 66 خطأ في السلبية، 458 صحيحة، 35 خطأ في الإيجابية.
- التغريدات الإيجابية: 40 خطأ في السلبية، 205 خطأ في المحايدة، 2784 صحيحة.



- هذه النتائج تعكس أداءً جيدًا للنموذج في تصنيف التغريدات بناءً على المشاعر المعبر عنها، مع تحقيق توازن جيد بين الدقة والاستدعاء ومقياس $F1$ source .

النتائج التي تم الحصول عليها عند أخذ عينة عشوائية :

ليبت بس التذاكر يقل سعره تكون ريال كافي	Neutral
لمحبين التصوير من الاماكن الجميلة ولمعرفة اوقات الافتتاح التواصل مع هيئة السياحة	Positive
متحف جميل يحكي تاريخ المدينة وسيرة الرسول صلى الله عليه وسلم يوجد مرشد معك اثناء الزيارة يقدم لك لمحة تاريخية عن المعرض رسوم الدخول ريال للشخص الواحد	Positive
يوجد به قطع أثرية من عصر صدر الإسلام والعصر العباسي والعصر الجاهلي بصراحه رائع	Positive
تستحق الزيارة مكان ممتع وجميل لكن للأسف اسعار المطاعم والكافيات والتسوق مرتفعه جدا	Neutral

طرق أخرى :

- يمكن حساب مقاييس الأداء المختلفة مثل الدقة (Micro, Macro, Weighted) في حالة وجود أكثر من صف في المسألة، وهذا يكون عادة في مشاكل التصنيف متعدد الفئات:

1. الدقة الصغرى (Micro-Averaging):

- في الدقة الصغرى، يتم حساب المقاييس (مثل الدقة، الاستدعاء، ومقياس $F1$) بحساب الإجمالي الكلي للتصنيفات الصحيحة والأخطاء (مثل الإيجابيات الخاطئة والسلبيات الخاطئة) عبر جميع الفئات.

- هذه الطريقة تعطي وزنًا متساويًا لكل عينة في المجموعة، مما يجعلها مناسبة عندما تكون العينات متساوية الأهمية.

2. الدقة الكبرى (Macro-Averaging):

- في الدقة الكبرى، يتم حساب المقاييس لكل فئة على حدة، ثم يتم أخذ المتوسط الحسابي لهذه المقاييس.
- هذه الطريقة تعطي وزنًا متساويًا لكل فئة، بغض النظر عن حجمها، وتكون مفيدة للموازنة بين الفئات في حالة عدم التوازن بين أحجام الفئات المختلفة.

3. الدقة الموزونة (Weighted-Averaging):

- في الدقة الموزونة، يتم حساب المقاييس لكل فئة على حدة، ثم يتم أخذ متوسط وزني لهذه المقاييس بناءً على حجم كل فئة.
- هذه الطريقة تعطي أهمية أكبر للفئات ذات الحجم الأكبر، وتكون مناسبة في الحالات التي يكون فيها التوزيع غير متوازن بين الفئات.

لحساب هذه المقاييس، يجب أن تكون لديك بيانات مفصلة حول النتائج الصحيحة والخاطئة لكل فئة في مجموعة الاختبار. هذا يتضمن عدد النتائج الإيجابية الصحيحة، الإيجابيات الخاطئة، السلبيات الصحيحة، والسلبيات الخاطئة لكل فئة.

Accuracy: 0.88				
Micro Precision: 0.88				
Micro Recall: 0.88				
Micro F1-score: 0.88				
Macro Precision: 0.79				
Macro Recall: 0.83				
Macro F1-score: 0.80				
Weighted Precision: 0.90				
Weighted Recall: 0.88				
Weighted F1-score: 0.89				
Classification Report				
	precision	recall	f1-score	support
Class 1	0.79	0.75	0.77	519
Class 2	0.59	0.82	0.69	559
Class 3	0.98	0.92	0.95	3029
accuracy			0.88	4107
macro avg	0.79	0.83	0.80	4107
weighted avg	0.90	0.88	0.89	4107

- 1-** Sana Alowaidi, Mustafa Saleh, Osama Abulnaja " Semantic Sentiment Analysis of Arabic Texts"
- 2 -** G. Salton, A. Wong, and C.-S. Yang, "A vector space model for automatic indexing," Communications of the ACM, vol. 18, pp. 613- 620, 1975.
- 3 -** A. Hotho, S. Staab, and G. Stumme, "Wordnet improves Text Document Clustering," 2003.
- 4 -** Z. Elberrichi, A. Rahmoun, and M. A. Bentaallah, "Using WordNet for Text Categorization," Int. Arab J. Inf. Technol., vol. 5, pp. 16-24, 2008.
- 5 -** Z. Elberrichi and K. Abidi, "Arabic text categorization: a comparative study of different representation modes," Int. Arab J. Inf. Technol., vol. 9, pp. 465-470, 2012.
- 6 -** S. A. Yousif, V. W. Samawi, I. Elkabani, and R. Zantout, "The Effect of Combining Different Semantic Relations on Arabic Text Classification."
- 7 -** G. Gautam and D. Yadav, "Sentiment analysis of twitter data using machine learning approaches and semantic analysis," in Contemporary Computing (IC3), 2014 Seventh International Conference on, 2014, pp. 437-442.
- 8 -** A. Balamurali, A. Joshi, and P. Bhattacharyya, "Robust sense-based sentiment classification," in Proceedings of the 2nd Workshop on Computational Approaches to Subjectivity and Sentiment Analysis, 2011, pp. 132-138.
- 9 -** M. K. Saad and W. Ashour, "Arabic morphological tools for text mining," Corpora, vol. 18, p. 19, 2010.
- 10 -** A. Farghaly and K. Shaalan, "Arabic natural language processing: Challenges and solutions," ACM Transactions on Asian Language Information Processing (TALIP), vol. 8, p. 14, 2009.
- 11 -** A. Shoukry and A. Rafea, "Preprocessing Egyptian dialect tweets for sentiment mining," in The Fourth Workshop on Computational Approaches to Arabic Script-based Languages, 2012, p. 47.
- 12 -** R. M. Duwairi and I. Qarqaz, "Arabic Sentiment Analysis using Supervised Classification," in Future Internet of Things and Cloud (FiCloud), 2014 International Conference on, 2014, pp. 579-583.
- 13 -** M. Abdul-Mageed, S. Kuebler, and M. Diab, "SAMAR: A system for subjectivity and sentiment analysis of social media Arabic," in 3rd Workshop on Computational Approaches to Subjectivity and Sentiment Analysis (WASSA), ICC Jeju, Republic of Korea, 2012.

- 14** - R. M. Duwairi, "Sentiment analysis for dialectical Arabic," in Information and Communication Systems (ICICS), 2015 6th International Conference on, 2015, pp. 166-170.
- 15** - M. Hammad and M. Al-awadi, "Sentiment Analysis for Arabic Reviews in Social Networks Using Machine Learning," in Information Technology: New Generations, ed: Springer, 2016, pp. 131-139.
- 16** - T. Elghazaly, A. Mahmoud, and H. A. Hefny, "Political Sentiment Analysis Using Twitter Data," in Proceedings of the International Conference on Internet of things and Cloud Computing, 2016, p. 11
- 17** - R. Baghel and R. Dhir, "A Frequent Concepts Based Document Clustering Algorithm," International Journal of Computer Applications, vol. 4, pp. 6-12, 2010.
- 18**- H. Saif, Y. He, and H. Alani, "Semantic sentiment analysis of twitter," in The Semantic Web–ISWC 2012, ed: Springer, 2012, pp. 508-524.
- 19**- C. C. Aggarwal and C. Zhai, Mining text data: Springer Science & Business Media, 2012.
- 20** - B. Pang and L. Lee, "Opinion Mining and Sentiment Analysis," Found. Trends Inf. Retr., vol. 2, pp. 1-135, 2008.